

EDA프로젝트 팀20 설명

1. 데이터에 대한 이해

```
RangeIndex: 159328 entries, 0 to 159327
Data columns (total 15 columns):
#   Column                Non-Null Count  Dtype  
---  -
0   거래id                159328 non-null  int64  
1   유형                  159328 non-null  object  
2   고객id                159328 non-null  int64  
3   코스ID                159328 non-null  int64  
4   포맷                  159328 non-null  object  
5   카테고리              159328 non-null  object  
6   코스(상품) 이름       159328 non-null  object  
7   거래일자              159328 non-null  object  
8   쿠폰이름              159328 non-null  object  
9   판매가격              159328 non-null  object  
10  결제수단              159328 non-null  object  
11  실거래금액            159328 non-null  int64  
12  쿠폰할인액            159328 non-null  object  
13  거래금액              159328 non-null  object  
14  환불금액             159328 non-null  object  
dtypes: int64(4), object(11)
memory usage: 18.2+ MB
```

- 데이터 타입 null값 확인

```

거래id      159328
유형        2
고객id      79615
코스ID      407
포맷        2
카테고리    11
코스(상품) 이름  407
거래일자    121645
쿠폰이름    1227
판매가격    625
결제수단    6
실거래금액  3366
쿠폰할인액  1201
거래금액    1606
환불금액    1763
dtype: int64

```

- 유형은 PAYMENT와 REFUND 두 종류
- 코스ID: 코스별로 고유 id
- 포맷 : 올인원, RED 중 하나
- 카테고리 : 분야별 11개의 카테고리
- 코스이름: 코스별 이름
- 거래일자: 2022. 12. 31 오후 10:12:33 같은 형식
- 쿠폰이름: '[WELCOME] 프로그래밍 3만원 할인' 같은 형식
- 판매가격: 사이트에 표기된 가격 (할인적용전)
- 결제수단: 결제수단에 따른 6가지 분류
- 실거래금액: 할인 혹은 환불이 적용된 가격 (음수 포함)
- 거래금액: 할인이 적용된 가격 (매출)
- 환불금액: 환불된 금액

2. EDA의 구체적 수행방법

1. 전처리 방법

- *사이트 는 값이 1개*밖에 없기때문에 불러오지 않음
- **df.info()**와 **df.nunique()**에서 확인한 값을 바탕으로 전처리해줌
 - *쿠폰할인액, 거래금액, 환불금액*을 *숫자형*으로 바꾸고 *결측치는 0*으로 채움
 - *판매가격 결측치*가 있는 row는 *제거*하고, *숫자형으로 타입을 바꿔줌*
 - 고객의 구매수를 쉽게 확인하기위해 컬럼추가 (int)
 - 구매횟수 : p_count (int)
 - 환불횟수 : r_count (int)


- 쿠폰 사용 유무 컬럼 추가
 - coupon (bool)
- 시간에 대한 처리를 편하게 하기 위해 **시간 컬럼추가**
 - 연월일 : p_date (datetime)
 - 요일 : p_week (월요일, 화요일, ..., 일요일)
 - 시간 : p_time (int)
- **판매가격보다 쿠폰할인액이 큰경우**
 - -> 잘못됨 (쿠폰할인액이 판매가격보다 클수 없음)
 - -> **쿠폰할인액을 판매금액과 동일하게 맞춰줌**
 - 위의 값을 '할인금액조정' 이라는 컬럼에 추가해줌 (int)
- ["강사", "내부직원", "참고용", "검수", "결제테스트", "테스트쿠폰"] 와 같은 값이 쿠폰이름에 있을시
 - 일반적인 쿠폰이 아니고 테스트용 쿠폰이기 때문에 **row를 제거함**
 - 완료된 모습

```

5 df.info()
16] ✓ 0.0s

<class 'pandas.core.frame.DataFrame'>
Index: 157478 entries, 0 to 159327
Data columns (total 24 columns):
#   Column                Non-Null Count  Dtype
---  -
0   거래id                157478 non-null int64
1   유형                  157478 non-null object
2   고객id                157478 non-null int64
3   코스ID                157478 non-null int64
4   포맷                  157478 non-null object
5   카테고리              157478 non-null object
6   코스(상품) 이름       157478 non-null object
7   거래일자              157478 non-null object
8   쿠폰이름               157478 non-null object
9   판매가격              157478 non-null int64
10  결제수단              157478 non-null object
11  실거래금액            157478 non-null int64
12  쿠폰할인액            157478 non-null int64
13  거래금액              157478 non-null int64
14  환불금액            157478 non-null int64
15  p_count               157478 non-null int8
16  r_count               157478 non-null int8
17  p_date                157478 non-null datetime64[ns]
18  p_week                157478 non-null object
19  p_time                157478 non-null int64
20  할인금액조정         157478 non-null int64
21  cp_tag                71775 non-null object
22  coupon                157478 non-null bool
23  p_month               157478 non-null int32
dtypes: bool(1), datetime64[ns](1), int32(1), int64(10), int8(2), object(9)
memory usage: 26.3+ MB

```



- 쿠폰 사용 유무에 따른 거래금액 boxplot
- 이상치 범위에 나오는 값이 많지만 데이터 확인 결과 다 필요한 값으로 판단되어 삭제하지 않음

2. 시각화 방법


- **seaborn** 과 **matplotlib**을 사용
 - **boxplot**
 - 이상치 확인, 전체적인 분포 확인
 - **scatterplot**
 - 쿠폰의 할인율을 기간별, 종류별에 따라 분포 확인
 - **pieplot**
 - 비율 확인
 - **histplot**
 - count기준, 비율 확인
 - **lineplot**
 - 시간에 따른 매출과 할인액 추이
 - **barplot**
 - 시간에 따른 값들 확인 / 카테고리별 값 확인
 - **word cloud**
 - 많이 사용된 쿠폰 시각화
-

3. 프로젝트의 예상 결과와 실제 결과 비교


1. 예상

- 쿠폰에 따라 매출등이 달라 질 것이라 예상
 - 쿠폰 운영 전략에 대해 다룸
-
-
- 아래 그래프는 1년간 사용된 쿠폰의 종류, 할인율을 나타내는 scatterplot 임
- 매월 초에 파란기둥이 있는걸 확인 할 수 있음
- 파란색은 프로모션 쿠폰이며, 50~100%정도의 높은 할인율의 쿠폰을 주기적으로 발행한다는 것을 알수 있음
- 0~30% 할인율로 밑에 전체적으로 깔려있는 초록색은 WELCOME 쿠폰으로 신규가입자에게 뿌리는것으로 꾸준히 발행됨


쿠폰사용 건 별 쿠폰할인율(%) - 2022년



- pieplot
- 쿠폰사용과 미사용의 비율을 보여줌
- *쿠폰을 사용하지 않은 그룹이 조금더 많은것을 알 수있음*




-
-
-
-
-
- histplot n회 거래한 사람의 숫자와 환불 비율을 나타냄
- 1 ~ 4회 거래하는 인원이 대부분임, 재구매율이 높지않음




-
-
-
-
-
- lineplot 월별 총 쿠폰 할인액 및 거래금액

- 매출과 쿠폰할인액(마케팅비용) 이 어느정도 상관관계를 보이는데 하나 **8,9월은 쿠폰할인액과 상관없이 매출이 높게 유지**되는 것을 볼 수있음




- 기간별 '코딩' 키워드 네이버 뉴스 발행수 (크롤링으로 수집)
- 꾸준히 발행수가 높아지긴 하지만 **8월과 연말에 많이 발행**된 것을 알 수 있음
- 해당 기간에 코딩에 대한 **사회적 관심도가 높아** 졌다고 볼 수 있음
- 8월에 쿠폰할인율이 빠졌지만 매출이 유지된 이유**라고 판단함




- 월별 쿠폰 사용율

- 전체적으로 50%에 가까우나 미사용이 조금 더 많음







- 월별 프로그래밍 수강 비율

- 매출이 높은 시기에 프로그래밍 수강수도 높아짐




- 시간별 결제량, 요일별 결제량
- 저녁시간에 결제량이 많음
- *월요일, 금요일, 일요일에 결제량이 많음*
- 주 고객층이 성인이다 보니 평일엔 바쁘게 지내다가 *금요일엔 '아 이번주말은 잘 보내야겠다',*
- *일요일, 월요일엔 '아 이번주 너무 놀았네,'* *현타*를 느끼며 *'이제부터 다시 열심히 살아야겠다'* 라고 생각하는 사람이 많아 *결제량과 쿠폰사용량이 늘어나는 시나리오*를 그려볼 수 있음






- 월별 카테고리별 구매횟수 그래프
- 프로그래밍과 데이터사이언스가 꾸준히 팔림
- 8~9월에 일러스트가 데이터사이언스를 잠깐 추월함




카테고리별 쿠폰 사용 비율

- 부업/창업, 투자/재테크 카테고리가 쿠폰 사용율이 다른 카테고리에 비해 높은것을 알수 있음



- 강의수 대비 쿠폰사용비율에 대한 그래프


- 투자/재테크, 부업/창업 은 절대적인 강의수가 적는데 비해 쿠폰 사용이 많았음
- 프로그래밍은 강의수가 많은데 비해 쿠폰 사용 비율이 적었음
- 부자재테크와 부업창업 카테고리는 커리어에 대한 공부라기 보다는 **부가적인 수업 카테고리**인 만큼, 커리어적인 다른 수업을 들으면서 **할인율이 높을때 '들어볼까?'** 하는 가벼운 마음의 **소비 심리를 예측** 해 봄



- 2회 이상 구매 고객 카테고리별 쿠폰사용 비율

- 투자재테크, 부업창업에서 쿠폰사용 비율이 높음
- 이를 보아 투자재테크와 부업창업 카테고리는 **쿠폰배포를 공격적으로 늘려 '할인하는데 들어볼까?'** 하는 심리를 더 자극하는 것이 매출에 도움이 될 것으로 보임

다회차 고객 '카테고리'별 쿠폰 사용 비율




- 쿠폰이름의 [] 안에 있는 내용의 **빈도**를 나타내는 워드클라우드
- 처음에 본 scatterplot 에서 볼 수 있었듯이 **웰컴, 프로모션, 신규가입자는, 5월, 증정** 등이 **많이 사용**되었다는 것을 알 수 있음




-
-
-
-
-
- WELCOME, 프로모션, 증정, 4만, 5월 등이 눈에 띄는 것을 다시 확인
- 아래 그래프는 색깔에 더해서 쿠폰 이름도 같이 볼 수 있게 하였음

쿠폰이름 Top 8 글자표시



- 5월 한달간의 쿠폰할인율 scatter그래프
- 월초에 프로모션이 강하게 있고, 신규와 5월, 등이 낮은 할인율에 고르게 분포해서
- 신규 유입을 꾸준히 노린다는 것을 알 수 있음



4. 프로젝트를 진행하며 느낀점

- 최우성
 - 처음 프로젝트를 시작하였을때 어떻게 진행해야 할지 감도 안왔지만 그래프를 그리다 보니 자연스럽게 진행 방향이 잡혔고, 그래서 시각화가 왜 중요한지 알 수 있었습니다. 그리고 잘못된 생각으로 해석하면 같은 자료를 두고도 다른 결론을 내릴 수 있음을 깨달았습니다. 조원들과 함께 토론하며 잘못된 부분을 서로 찾아줘서 큰 도움이 되었고, 같은 주제로 다같이 토론 하며 진행하니 즐거웠습니다.
 - 처음에는 '이거 어떻게 해야하죠?' 라고 물으면 다들 '그러게요..?' 라고 했었는데 마지막에 가서는 '이거 필요하겠는 데요?' 라고 말하면 누군가가 척척 만들어서 오는걸 보고 다들 짧은기간에 많이 능숙해 졌다고 생각했습니다.

- 저희팀은 쿠폰을 주제로 잡고 EDA를 진행하였는데 예상과 다른 결과들도 많이나와, 직감으로 '이렇지 않을까?' 와 실제로 데이터를 분석하는 것엔 차이가 크다는 것을 느꼈습니다.
- 조용준
 - 프로젝트 진행 이전에는 매출액의 문제점들을 월별로 잘 보여 줄 수 있을 것이라고 생각했는데, 생각보다 많이 다양한 이유로,, 쿠폰과 연관이 있거나 연관이 없는 허무한 결과가 종종 있어서 찾는 과정이 순탄치 않았습니다.
 - 프로젝트를 진행하면서, 하나의 서비스에는 많은 요인들이 존재한다는걸 알았습니다. 또한, 매일 팀원들에게 혹은 오늘 발표에서, 어떻게 설득을 효과적으로 할 수 있을까 라는 형식을 고민하고, 그래프를 그려보는 과정에서 많은 실력 향상이 있었습니다.
- 심성훈
 - refund가 있는 고객 데이터로 매출액을 정제하려고했는데, 이게 뭐라고 정성을 들였는지 모르겠네요. 최대한 빠르게 나머지전처리 요소와 그래프 주제에 맞게 준비하도록 하겠습니다.
 - 아 그리고 한가지 느낀점이 뭐였냐면, EDA 주피터 파일로 코드 테스트하고 열심히 코드짜고 그랬는데, 사실 의도한대로 테스트가 안되어도 어쨌든 컬럼하나 만들겠다고 혼자서 난리를 쳤죠. 근데 필요한 코드만 짚 뽑아서 간단한 코드로 만들었더니, 구현 안되던 코드도 구현이 되버려가지고 (결측치 딴서너리였나 할겁니다.) 이제와서 구현이된거를 어떻게 또 짜야하는데 난감합니다. 허허..
- 신포숙
 - 머릿속 구상을 코드로 구현하는 것이 생각보다 오래 걸려서 놀랐습니다.
 - 다른 분들의 코드를 보면서 배울 점이 있어서 좋았습니다.
 - 팀으로 함께하는 경험을 할 수 있어서 좋았습니다. 의지가 많이 됐어요.
 - 시간이 흘러 시각화의 실력이 늘 수록 EDA에 대한 욕심이 생기는 것을 느꼈습니다. 하루 이틀 정도의 시간이 더 있었다라면 좀더 깊게 파고들어 유의미한 결과를 도출할 수 있었을텐데 아쉬웠습니다
- 정충원
 - 처음 데이터분석 프로젝트를 진행하기에 어떻게 문제 정의하고 풀어나가야하는지 어려움이 많았으나 팀원분들의 도움과 회의를 통해 실마리를 잡을수 있었던것 같다. 파이썬, 판다스와 이를 시각화 하는부분에서 미숙한 점이 많아 공부를 하며 기여하기에는 다소 촉박했고 타 조의 발표를 들으며 아 나도 이런부분을 좀더 도입해 볼걸 하는 아쉬움이 있었다. 더불어 문제 해결과정에서도 내가 설정한 문제를 확실히 근거있게 풀었는가에 대해서도 부족한 느낌이다.첫 데이터 분석 프로젝트에 좋은 팀원분들과 함께 나름의 결과물을 완성할수 있어서 좋았다.
- 박성빈
 - 제시된 목적성이나 방향성 없이, 있는 데이터에서 파생 가능한 모든 분석들을 제시하다보니 정신없고, 생각들을 한 곳에 모으는 과정이 힘들었습니다. 팀으로 EDA 프로젝트를 경험해볼 수 있어서 좋았습니다.

최종소감

- 힘들었지만 조원들과 같이 해서 즐거웠습니다 ㅎㅎ